

CHƯƠNG 3 MÔ HÌNH HÓA KỊCH BẢN PHÁT GÓC TRONG MÔI TRƯỜNG GRF

3.1 Giới thiệu về quá trình quyết định Markov quan sát một phần phi tập trung (Dec - POMDP)

Trước tiên, để áp dụng thuật toán HES-COMA cần mô hình hóa bài toán phạt góc trong môi trường GRF dựa trên khung tham chiếu Dec-POMDP chuẩn. Ngoài ra, kết hợp cấu trúc phân cấp Hierarchical bằng việc cấu trúc hóa môi trường theo 2 tầng chính gồm tầng chiến lược toàn cục và tầng kỹ thuật cục bộ, kết hợp với việc thiết lập các trường năng lượng vào thành phần quan sát và phần thưởng.

Quá trình quyết định Markov quan sát một phần phi tập trung (Dec-POMDP) là một mô hình phối hợp và ra quyết định giữa nhiều tác nhân. Đây là một mô hình xác suất có thể xem xét sự không chắc chắn trong kết quả, cảm biến và giao tiếp (tức là giao tiếp tốn kém, chậm trễ, nhiễu hoặc không tồn tại). Đây là sự tổng quát hóa của quy trình quyết định Markov (MDP) và quy trình quyết định Markov quan sát được một phần (POMDP) để xem xét nhiều tác nhân phân tán. Dec-POMDP là một bộ 7 phần tử $(S, \{A_i\}, T, R, \{\Omega_i\}, O, \gamma)$, Trong đó:

- S là một tập hợp các trạng thái,
- A_i là một tập hợp các hành động dành cho tác nhân i , với $A = \times_i A_i$ là tập hợp các hành động phối hợp,
- T là một tập hợp các xác suất chuyển đổi có điều kiện giữa các trạng thái, $T(s, a, s') = P(s' | s, a)$,
- $R : S \times A \rightarrow R$ là hàm phần thưởng.
- Ω_i là một tập hợp các quan sát dành cho tác nhân i , với $\Omega = \times_i \Omega_i$ là tập hợp các quan sát chung,
- O là một tập hợp các xác suất quan sát có điều kiện. $O(s', a, o) = P(o | s', a)$
- $\gamma \in [0, 1]$ là hệ số chiết khấu.

Tại mỗi bước thời gian, mỗi tác nhân thực hiện một hành động $a_i \in A_i$, trạng thái được cập nhật dựa trên hàm chuyển đổi $T(s, a, s')$ (sử dụng trạng thái hiện tại và hành động chung), mỗi tác nhân quan sát một dữ liệu dựa trên hàm quan sát. $O(s', a, o)$ (sử dụng trạng thái tiếp theo và hành động chung) và phần thưởng được tạo ra cho toàn đội dựa trên hàm thưởng $R(s, a)$. Mục tiêu là tối đa hóa phần thưởng tích lũy kỳ vọng trong một số bước hữu hạn hoặc vô hạn. Các bước thời gian này lặp lại cho đến một chân trời nhất định (gọi là chân trời hữu hạn - finite horizon) hoặc mãi mãi (gọi là chân trời vô hạn - infinite horizon). Hệ số chiết khấu γ duy trì tổng hữu hạn trong trường hợp chân trời vô hạn ($\gamma \in [0, 1)$).

3.2 Mô hình hóa kịch bản Phạt góc (Corner Kick)

3.2.1 Tập trạng thái (S)

Tập trạng thái bao gồm các thông tin của môi trường thay đổi

Sử dụng toàn bộ raw_observations hoặc wrapper simple115_v2.

- Bóng: tọa độ bóng, hướng di chuyển của bóng, đội sở hữu bóng.
- Đội nhà (Left): Toàn bộ 11 tọa độ hướng di chuyển, vai trò của cầu thủ đội nhà.
- Đội thủ (Right): Toàn bộ 11 tọa độ hướng di chuyển, vai trò của cầu thủ đội nhà.
- Score: tỉ số trận đấu

3.2.2 Tập hành động của tác nhân i (A_i)

Chia tập gồm 16 hành động thành 2 lớp xử lý

$A_{\{global, i\}}$ (Chiến lược): ánh xạ các hành động di chuyển rời rạc gồm 8 hướng di chuyển và hành động STAY.

- 8 hướng di chuyển: trái, phải, trên, dưới, trên bên trái, trên bên phải, dưới bên trái, dưới bên phải
- Hành động STAY: đặt lại hướng di chuyển, không làm gì cả

$A_{\{local, i\}}$ (Kỹ thuật): chỉ kích hoạt khi $a_{\{global\}} = STAY$.

- Hành động tấn công: dứt điểm, chuyền ngắn, chuyền bổng, chuyền dài
- Hành động hỗ trợ/phòng ngự: xoạc/trượt, rê bóng.

Joint Action a : sự kết hợp hành động của tất cả các tác nhân đang được điều khiển.

3.2.3 Xác suất chuyển đổi trạng thái (T)

$T(s, a, s') = P(s' | s, a)$: chính là bộ giả lập vật lý 3D của GRF. Nó tính toán vị trí tiếp theo của bóng và cầu thủ sau khi thực hiện các cú sút hoặc đường chuyền trong kịch bản phạt góc

3.2.4 Hàm phần thưởng R

Hàm phần thưởng không chỉ là kết quả của trận đấu mà còn bao gồm phần thưởng định hình từ trường năng lượng:

R_{env} : +1 nếu ghi bàn, -1 nếu bị mất bóng/thủng lưới

$r_{energy, i}$: được tính bằng độ chênh lệch năng lượng tại vị trí tác nhân i $E(p_t) - E(p_{t+1})$. Nếu tác nhân di chuyển về phía bóng hoặc khoảng trống (năng lượng thấp) thì $r > 0$

Tổng phần thưởng: $R = R_{env} + \alpha \sum_{i=1}^{11} r_{energy, i}$ (với α là trọng số)

3.2.5 Tập quan sát của tác nhân i (Ω_i)

Global Observation ($\Omega_{G,i}$): sử dụng ray-based để tác nhân quét xung quanh để nhận giá trị năng lượng từ trường tiềm năng. Nhìn độ dốc của năng lượng để quyết định hướng chạy chỗ

- Trường năng lượng (E)

$$E_{total}(x, y) = E_{ball}(x, y) + E_{goal}(x, y) + \sum_{j=1}^M E_{opp_j}(x, y) + \sum_{k=1}^K E_{team_k}(x, y)$$

Trong đó:

E_ball (Năng lượng từ Bóng):

- w_ball mang giá trị âm rất lớn.
- Lực hút ưu tiên số 1 để lôi kéo tác nhân chạy về phía điểm rơi của bóng.

E_goal (Năng lượng từ Khung thành đối phương):

- w_goal mang giá trị âm vừa phải.
- Tạo lực hút định hướng để tác nhân không chạy ngược về sân nhà mà luôn hướng sự chú ý vào khu vực cấm địa.

E_opp (Tổng năng lượng từ Đối thủ):

- w_opp mang giá trị dương lớn.
- Tạo ra các chương ngại vật tàng hình. Mật độ đối thủ càng đông, tổng năng lượng khu vực đó càng dương mạnh, buộc Agent phải tránh xa để tìm khoảng trống.

E_team (Tổng Năng lượng từ Đồng đội):

- w_team mang giá trị dương nhỏ
- Lực đẩy nhẹ để tác nhân tránh dẫm chân vào vị trí đồng đội của mình, đảm bảo đội hình dàn trải hợp lý trong vòng cấm, không tranh chấp cùng một vị trí với nhau.

Local Observation ($\Omega_{L,i}$): Thông tin chi tiết khi tiếp xúc bóng: vị trí tương đối của bóng, vận tốc bóng, mức độ mệt mỏi của tác nhân i.

3.2.6 Tập xác suất quan sát (O)

$O(s', a, o)$: ánh xạ từ trạng thái 3D thực tế sang các vector quan sát cục bộ (tia quét và dữ liệu đội bóng) mà tác nhân nhận được tại bước thời gian tiếp theo

3.2.7 Hệ số chiết khấu (γ)

$\gamma \in [0.95, 0.99]$: trong kịch bản phạt góc, tầm nhìn xa quan trọng vì việc chạy chỗ diễn ra trong nhiều bước trước khi hành động ghi bàn có thể xuất hiện

3.3 Thông tin các tham số cụ thể ánh xạ từ GRF

3.3.1 Xây dựng trường năng lượng

Công thức tổng quát:

$$E(x, y) = \sum_{i=1}^N w_i \cdot \exp \left(- \left[\frac{(x - \mu_{x_i})^2}{\sigma_{x_i}^2} + \frac{(y - \mu_{y_i})^2}{\sigma_{y_i}^2} \right] \right)$$

Trong đó:

- $E(x, y)$: Tổng mức năng lượng (độ nguy hiểm/thuận lợi về mặt chiến thuật) tại tọa độ (x, y)
- N : Tổng số các thực thể tạo ra lực trường (Bóng, Khung thành, Cầu thủ đối phương, Đồng đội).
- w_i : Trọng số cực đại của thực thể i .
 - $w_i < 0$: Tạo ra hố năng lượng (Lực hút - Attractive).
 - $w_i > 0$: Tạo ra đỉnh năng lượng (Lực đẩy - Repulsive).
- (μ_{x_i}, μ_{y_i}) : Tọa độ thực thể của thực thể i trên sân (tâm của lực).
- $(\sigma_{x_i}, \sigma_{y_i})$: Độ lệch chuẩn, đại diện cho phạm vi ảnh hưởng của thực thể i .

(Ví dụ: Một hậu vệ cao to sẽ có σ lớn hơn, kiểm soát một vùng không gian rộng hơn).

Tâm điểm hút (Ball): *ball* $[x, y]$ - vị trí của quả bóng, tạo hố năng lượng tại tọa độ bóng

Điểm đích (Opponent Goal): Hằng số tọa độ $[1, (-0.044; 0.044)]$, đại diện cho lực hút cố định giúp định hướng tấn công

Nguồn đẩy (Opponent): *right_team*: $[x, y]$ - vị trí của đối thủ tương ứng với 11 tác nhân. Mỗi tọa độ đối thủ tạo một đỉnh năng lượng dương để tác nhân né tránh, tìm kiếm khoảng trống

Nguồn đẩy nhẹ (Teammates): *left_team*: $[x, y]$ - vị trí của người chơi. Sử dụng nguồn đẩy nhẹ để tránh việc các tác nhân tấn công đứng trùng vị trí nhau

Các quan sát cập nhật real-time, dự báo vị trí các đỉnh năng lượng tại $t + 1$ để tác nhân di chuyển:

- *ball_direction*[x, y, z]: vector chuyển động của quả bóng
- *left_direction*[x, y]: vector 11 phần tử với các vector chuyển động của 11 người chơi đội nhà
- *right_direction*[x, y]: vector 11 phần tử với các vector chuyển động của 11 người chơi của đối thủ

3.3.2 Cấu trúc học tập phân cấp

Lớp toàn cục (GAgent - Global Spatial Hierachy) học cách di chuyển chiến lược:

Observations:

left_team[active]: tọa độ hiện tại của chính tác nhân đó để lấy giá trị năng lượng E tại đó

Ray-based observation: sử dụng tọa độ *left_team[active]* làm gốc, quét xung quanh dựa trên bản đồ năng lượng tổng hợp từ *ball*, *right_team* và *left_team*

sticky_actions: để biết trạng thái di chuyển hiện tại

Actions:

Ánh xạ trực tiếp tới các hành động di chuyển

- *action_left* = 1: chạy sang trái, hành động dính.
- *action_top_left* = 2: chạy về phía trên bên trái, hành động dính.
- *action_top* = 3: chạy lên trên, tác dụng bám dính.
- *action_top_right* = 4: chạy lên góc trên bên phải, hành động dính.
- *action_right* = 5: chạy sang phải, hành động dính.
- *action_bottom_right* = 6: chạy xuống góc dưới bên phải, thao tác dính.
- *action_bottom* = 7: chạy xuống đáy, tác dụng dính.
- *action_bottom_left* = 8: chạy xuống phía dưới bên trái, hành động dính.

Hành động “STAY” của GAgent được ánh xạ tới *action_idle* = 0 hoặc *action_release_direction* = 14

- *action_idle* = 0: hành động không gây ảnh hưởng, các hành động dính không bị ảnh hưởng (người chơi vẫn duy trì hướng di chuyển của mình).
- *action_release_direction* = 14: đặt lại hướng di chuyển

Lớp cục bộ (LAgent - Local Spatial Hierachy) học các hành động kỹ thuật khi GAgent đã đứng đúng vị trí

Observations:

- *ball*[x, y, z]: vị trí của quả bóng
- *ball_owned_team* {-1, 0, 1}: thể hiện các giá trị tương ứng -1 = bóng không thuộc sở hữu, 0 = đội bên trái sở hữu, 1 = đội bên phải.
- *left_team_tired_factor*[*active*]: vector N phần tử số thực trong phạm vi {0...1}. 0 nghĩa là người chơi hoàn toàn sung sức. Tham số này ảnh hưởng đến độ chính xác của hành động kỹ thuật

Actions:


- *action_long_pass* = 9: thực hiện một đường chuyền dài cho cầu thủ trong đội của bạn. Cầu thủ nhận bóng sẽ được tự động xác định dựa trên hướng di chuyển.
- *action_high_pass* = 10: thực hiện một đường chuyền bổng, tương tự như *action_long_pass*.
- *action_short_pass* = 11: thực hiện một đường chuyền ngắn, tương tự như *action_long_pass*.
- *action_shot* = 12: hành động ưu tiên cao nhất trong phạt góc.
- *action_sliding* = 16: dùng khi LAgent đánh giá cần "Chặn" (Intercept) bóng từ đối phương.

CHƯƠNG 4 ÁP DỤNG THUẬT TOÁN HỌC TĂNG CƯỜNG ĐA TÁC TỬ

4.1 Giới thiệu thuật toán HES-COMA (Hierarchical Energy Strategy Counterfactual Multi-Agent Policy Gradients)

Với sự kết hợp giữa cấu trúc phân cấp và trường năng lượng, HES-COMA được biết đến là một thuật toán học tăng cường đa tác tử giải quyết các vấn đề về xử lý dữ liệu quan sát đa dạng, đánh giá đóng góp trong môi trường đa tác nhân động. Thuật toán đề xuất phương pháp học tăng cường phân cấp tách biệt không gian toàn cục và cục bộ thông qua khung trường năng lượng để gán trị năng lượng dựa trên các yếu tố môi trường chính nhằm mục đích đánh giá vị trí chiến lược của mỗi tác nhân. Sự kết hợp này giải quyết cả vấn đề đa dạng dữ liệu phát sinh trong môi trường mà trạng thái thay đổi liên tục, nhanh chóng và thách thức về sự đo lường đóng góp của các tác nhân

Thuật toán được xây dựng với hai bước chính. Bước đầu tiên, cấu trúc học tập phân cấp phân chia không gian học tập thành các lớp toàn cục và cục bộ, điều này giúp làm giảm độ phức tạp của việc học. Ở lớp toàn cục, các hành động chuyển động chiến lược được định hướng và ánh xạ bởi kỹ thuật trường năng lượng được học, trong khi ở lớp cục bộ, các hành động chiến thuật như sút, chuyền và trượt được học. Đến bước thứ hai, bằng cách gán giá trị năng lượng cho các đặc điểm môi trường quan trọng, phương pháp trường năng lượng khuyến khích các tác nhân học các vị trí và hành động tối ưu trên toàn trường dựa trên khoảng cách và trạng thái. Trường năng lượng này được cập nhật theo thời gian thực theo trạng thái trò chơi và được sử dụng để tính toán giá trị năng lượng cho vị trí hiện tại của mỗi tác nhân, tạo điều kiện thuận lợi cho việc đánh giá chính xác hơn các đóng góp cá nhân.



Hình 2. Khung HES-COMA dành cho các trò chơi thể thao

4.1.1 Học tăng cường phân cấp

Học tăng cường phân cấp là một phương pháp được nghiên cứu rộng rãi để giảm độ phức tạp, học chính sách hiệu quả trong môi trường có không gian trạng thái và hành động quy mô lớn.

Bằng cách phân tách các vấn đề phức tạp thành các mục tiêu tổng quát, mang tính chiến lược tại tầng cấp cao và các nhiệm vụ phụ cấp thấp hơn nhận mục tiêu từ tầng cấp cao sau đó thực hiện thông qua các hành động cụ thể, chi tiết để hoàn thành mục tiêu. Điều này cho phép học tập nhanh chóng và ổn định, bất chấp sự đa dạng quan sát ngày càng tăng. Một số phiên bản áp dụng phương pháp phân cấp như H-DQN, chỉ đơn giản là mở rộng DQN thông thường thành cấu trúc gồm 2 tầng mạng. Mạng Q cấp cao đặt ra và quyết định các mục tiêu cần đạt, mạng Q cấp thấp quyết định các hành động cụ thể để đạt được mục tiêu đó, kết quả thực nghiệm cho thấy H-DQN vượt

trội hơn DQN truyền thống trong các môi trường trò chơi phức tạp. Điều này dễ hiểu vì việc chia nhỏ giúp các tác nhân không bị lạc lối trong không gian tìm kiếm khổng lồ. Một ví dụ khác tương tự đó là phân cấp chia sẻ được học siêu dữ liệu (Meta-Learned Hierarchies) thú vị hơn một chút, đó là thay vì chỉ có hai tầng cứng nhắc thì nó dùng một chính sách chính để quản lý và chuyển đổi linh hoạt giữa nhiều chính sách con. Khi tình huống thay đổi, chính sách nhận ra và kích hoạt chính sách con phù hợp nhất. Điều này mang lại khả năng thích ứng cao với môi trường động, điểm cộng lớn trong thực tế.

4.1.2 Trường năng lượng

Trường năng lượng là kỹ thuật lượng hóa không gian được sử dụng chỉ ở tầng toàn cục để dẫn đường, lập kế hoạch đường đi cho tác nhân. Phương pháp này sử dụng hàm phân phối Gaussian để gán giá trị năng lượng cho các điểm trên không gian sân đấu dựa trên các yếu tố môi trường quan trọng. Phương pháp này tiếp cận 2 khái niệm gồm lực hút và lực đẩy.

Lực hút mang giá trị năng lượng âm hướng tới các mục tiêu mà tác nhân cần tiếp cận. Các yếu tố đặc biệt quan trọng trong môi trường sẽ mang giá trị âm rất lớn. Lực này dẫn dắt các tác nhân di chuyển đến những vị trí mà tại đó có thể hàm phần thưởng nhận được sẽ có lợi cho tác nhân.

Ngược lại, lực đẩy lại mang giá trị năng lượng dương được gán cho các chướng ngại vật, hay các yếu tố môi trường mà sẽ có xu hướng hỗ trợ tốt tránh cản trở các tác nhân khác khi cần sự phối hợp giữa các nhiều tác nhân. Phương pháp này có thể mở rộng sang nhiều môi trường đa tác tử khác nhau, nên cũng khả thi đối với môi trường tương tác lớn như các trò chơi thể thao. Trong một kịch bản thể thao, nhiều người chơi liên tục tương tác trong một không gian hạn chế đồng thời theo đuổi các mục tiêu khác nhau như giành quyền kiểm soát bóng hoặc ghi bàn. Trong suốt quá trình này, mỗi người chơi phải xác định vị trí tối ưu của mình trong thời gian thực để thích ứng với các điều kiện thay đổi nhanh chóng. Tận dụng quan điểm này, nghiên cứu hiện tại đã điều chỉnh và áp dụng phương pháp trường năng lượng đã được chứng minh từ lĩnh vực robot và lái xe tự hành vào bối cảnh trò chơi thể thao, từ đó đề xuất một phương pháp để xác định các vị trí chiến lược trong môi trường thể thao đa tác nhân.[]

Bằng cách sử dụng trường năng lượng để học các định vị mang tính chiến lược, cho phép học tập hiệu quả, di chuyển tới các vị trí chiến lược trong môi trường trò chơi thể thao năng động. Kết hợp việc gán lực hút và lực đẩy cho quá trình định vị của mỗi tác nhân, giải quyết đáng kể công việc điều hướng cho tác nhân đồng thời di chuyển, đánh giá đóng góp của từng tác nhân, học các chính sách một cách có hiệu quả hơn.

4.2 Các bước thực hiện

Khung học tăng cường đa tác tử với cấu trúc phân cấp chia quá trình học tập thành phân cấp không gian toàn cục và phân cấp không gian cục bộ. Ở giai đoạn đầu tiên, hệ thống phân cấp không gian toàn cầu cho phép tác nhân (GAgent) học cách chuyển động tới vị trí chiến lược thông qua trường năng lượng. Ở giai đoạn thứ hai, hệ thống phân cấp không gian cục bộ sử dụng vị trí chiến lược được xác định ở giai đoạn trước đó để tác nhân (LAgent) học các hành động chiến thuật như sút bóng, chuyền bóng hay cướp bóng. Quá trình xác định hành động chỉ được diễn ra khi hệ thống phân cấp không gian toàn cầu xảy ra hành động dừng lại thì hành động ở giai đoạn thứ hai này mới được áp dụng vào môi trường.

4.2.1 Học phân cấp không gian toàn cục để di chuyển vị trí chiến lược

4.2.1.1 Bước khởi tạo

Bước 1: Khởi tạo ngẫu nhiên tham số Actor θ^g và Critic ϕ^g

Bước 2: Cấu hình môi trường huấn luyện cấp toàn cục $\mathcal{E}_g$

- Môi trường $\mathcal{E}_g$ chỉ cho phép 8 hướng di chuyển + 2 hành động dừng

4.2.1.2 Vòng lặp chính (episode = 1 đến N_{ep})

Mỗi episode thực hiện thông qua 2 vòng lặp con:

Bước 3: Reset môi trường $\mathcal{E}_g$, quan sát trạng thái toàn cục ban đầu s_0 . Các quan sát bao gồm: Ray-based + Energy Field

Bước 4: Khởi tạo Buffer rỗng: Buffer $\leftarrow \emptyset$

Vòng lặp thời gian ($t = 0$ đến EpisodeMaxStep)

Bước 5: Lấy quan sát riêng của GAgent từ trạng thái hiện tại (gồm thông tin Ray và Energy Field):

$$o_t^g \leftarrow \text{PartialObservation}(s_t)$$

Bước 6: Lấy mẫu hành động từ chính sách Actor hiện tại:

$$a_t^g \leftarrow \pi_{\theta^g}(o_t^g)$$

Bước 7: Thực thi hành động a_t^g trong môi trường

Bước 8: Quan sát kết quả sau hành động:

$$s_{t+1}, r_t^g, d \leftarrow \mathcal{E}_g$$

Trong đó:

r_t^g : phần thưởng dựa trên Energy Field

d : cờ kết thúc episode

Bước 9: Lưu transition vào Buffer:

$$\text{Buffer} \leftarrow \text{Buffer} \cup \{(s_t, o_t^g, a_t^g, r_t^g, s_{t+1}, d)\}$$

Bước 10: Cập nhật trạng thái: $s_t \leftarrow s_{t+1}$

Bước 11: Nếu $d = \text{true} \rightarrow$ kết thúc episode (break)

Cập Nhật COMA Trên Toàn Bộ Dữ Liệu Buffer

Với mỗi transition $(s, a^g, a^g, r^g, s', d)$ trong Buffer:

Bước 12: Tính giá trị Q từ Critic trung tâm:

$$Q_{\phi^g}^{central}(s, a^g) \text{ via Critic}$$

Bước 13: Tính baseline (kỳ vọng có trọng số theo chính sách):

$$b(s) = \sum_{a'} \pi_{\theta^g}(a' | o^g) Q_{\phi^g}^{central}(s, a')$$

Bước 14: Tính TD-error (sai số Temporal Difference):

$$\delta \leftarrow r^g + \gamma Q_{\phi^g}^{central}(s', a'^g) - Q_{\phi^g}^{central}(s, a^g)$$

Bước 15: Cập nhật Critic ϕ^g bằng cách tối thiểu hóa $(\delta)^2$

$$\text{Update Critic } \phi^g \text{ to minimize } (\delta)^2$$

Bước 16: Tính lợi thế phản thực tế (counterfactual advantage):

$$Adv^g \leftarrow Q_{\phi^g}^{central}(s, a^g) - b(s)$$

Bước 17: Cập nhật Actor θ^g theo gradient:

$$\theta^g \leftarrow \theta^g + \nabla_{\theta^g} \log \pi^g(a^g | o^g) \cdot Adv^g$$

Bước 18: Kết thúc vòng lặp cập nhật COMA, xóa sạch Buffer: Buffer $\leftarrow \emptyset$

Kết thúc vòng lặp chính

Bước 19: Sau N_{ep} , trả về bộ tham số đã huấn luyện bao gồm θ^g , ϕ^g đã được huấn luyện bởi GAgent

4.2.1.3 Mã giả

Algorithm 1 HES-COMA(Step 1: Train Global-Level GAgent)
1: Initialize θ^g, ϕ^g randomly
2: Configure environment $\mathcal{E}_g$ for global-level training
3: // $\mathcal{E}_g$ allows only 8-direction movement + stay
4: for $episode = 1$ to N_{ep} do
5: Reset $\mathcal{E}_g$; observe initial global state s_0 (Ray-based + Energy Field)
6: Initialize Buffer = $\emptyset$
7: for $t = 0$ to EpisodeMaxStep do
8: $o_t^g \leftarrow \text{PartialObservation}(s_t)$ {GAgent's own observation (Ray info, Energy Field.)}
9: $a_t^g \leftarrow \pi_{\theta^g}^g(o_t^g)$ {Sample action (move or stay)}
10: Execute a_t^g in $\mathcal{E}_g$
11: Observe s_{t+1}, r_t^g, d {Reward based on Energy Field}
12: Buffer $\leftarrow$ Buffer $\cup \{(s_t, o_t^g, a_t^g, r_t^g, s_{t+1}, d)\}$
13: $s_t \leftarrow s_{t+1}$
14: if d is true then
15: break {Episode ends}
16: end if
17: end for
18: // COMA Update over collected transitions
19: for each $(s, o^g, a^g, r^g, s', d)$ in Buffer do
20: Compute $Q_{\phi^g}^{central}(s, a^g)$ via Critic
21: Compute baseline $b(s) = \sum_{a'^g} \pi_{\theta^g}^g(a'^g o^g) Q_{\phi^g}^{central}(s, a'^g)$
22: $\delta \leftarrow r^g + \gamma Q_{\phi^g}^{central}(s', a'^g) - Q_{\phi^g}^{central}(s, a^g)$ {TD-error}
23: Update Critic ϕ^g to minimize $(\delta)^2$
24: $Adv^g \leftarrow Q_{\phi^g}^{central}(s, a^g) - b(s)$ {counterfactual advantage}
25: Update Actor θ^g using $\nabla_{\theta^g} \log \pi^g(a^g o^g) Adv^g$
26: end for
27: Buffer $\leftarrow \emptyset$
28: end for
29: Return θ^g, ϕ^g {Trained GAgent (global)}

4.2.2 Học phân cấp không gian cục bộ cho các hành động chiến thuật

4.2.2.1 Bước khởi tạo

Bước 1: Khởi tạo ngẫu nhiên tham số Actor θ^l và Critic ϕ^l

Bước 2: Cố định θ^l từ bước 1 - GAgent không được cập nhật trong giai đoạn này

Bước 3: Cấu hình môi trường huấn luyện cấp toàn cục $\mathcal{E}_l$

- Hành động di chuyển của GAgent do $\pi_{\theta^g}^g$ đảm nhận
- LAgent chỉ hành động khi GAgent = STAY

4.2.2.2 Vòng lặp chính (episode = 1 đến N_ep)

Mỗi episode thực hiện thông qua 2 vòng lặp con:

Bước 4: Reset môi trường $\mathcal{E}_l$, quan sát trạng thái toàn cục ban đầu s_0 .

Bước 5: Khởi tạo Buffer cục bộ rỗng: $Buffer_l \leftarrow \emptyset$

Vòng lặp thời gian (t = 0 đến EpisodeMaxStep)

Bước 6: Lấy quan sát riêng của GAgent từ trạng thái hiện tại:

$$o_t^g \leftarrow PartialObservation_g(s_t)$$

Bước 7: Lấy quan sát riêng của LAgent từ trạng thái hiện tại:

$$o_t^l \leftarrow PartialObservation_l(s_t)$$

Bước 8: GAgent lấy mẫu hành động toàn cục (di chuyển hoặc đứng yên):

$$a_t^g \leftarrow \pi_{\theta^g}^g(o_t^g)$$

Bước 9: LAgent lấy mẫu hành động cục bộ (sút, chuyền, cướp bóng):

$$a_t^l \leftarrow \pi_{\theta^l}^l(o_t^l)$$

Bước 10: Kiểm tra hành động của GAgent:

Nếu $a_t^g = STAY \rightarrow$ Thực thi a_t^l trong $\mathcal{E}_l$ (LAgent được phép hành động)

Nếu $a_t^g \neq STAY \rightarrow$ Thực thi a_t^g trong $\mathcal{E}_l$ (tác nhân di chuyển theo GAgent, LAgent không hành động)

Bước 11: Quan sát kết quả sau hành động:

$$s_{t+1}, r_t^l, d \leftarrow \mathcal{E}_l$$

Trong đó:

r_t^l : phần thưởng cục bộ

d: cờ kết thúc episode

Bước 12: Lưu transition vào Buffer:

$$Buffer_l \leftarrow Buffer_l \cup \{(s_t, o_t^l, a_t^l, r_t^l, s_{t+1}, d)\}$$

Bước 13: Cập nhật trạng thái: $s_t \leftarrow s_{t+1}$

Bước 14: Nếu $d = \text{true} \rightarrow$ kết thúc episode (break)

Cập Nhật COMA Trên Toàn Bộ Dữ Liệu Buffer

Với mỗi transition (s, a^l, a', r^l, s', d) trong $Buffer_l$:

Bước 15: Tính giá trị Q từ Critic trung tâm của LAgent:

$$Q_{\phi^g}^{central}(s, a^l) \text{ via Critic}$$

Bước 16: Tính baseline (kỳ vọng có trọng số theo chính sách LAgent):

$$b(s) = \sum_{a^{l'}} \pi_{\theta^l}(a^{l'} | o^l) Q_{\phi^l}^{central}(s, a^{l'})$$

Bước 17: Tính TD-error (sai số Temporal Difference) của LAgent:

$$\delta_l \leftarrow r^l + \gamma Q_{\phi^l}^{central}(s', a^{l'}) - Q_{\phi^l}^{central}(s, a^l)$$

Bước 18: Cập nhật Critic ϕ^l bằng cách tối thiểu hóa $(\delta_l)^2$

$$\text{Update Critic } \phi^l \text{ to minimize } (\delta_l)^2$$

Bước 19: Tính lợi thế phản thực tế (counterfactual advantage):

$$Adv^l \leftarrow Q_{\phi^l}^{central}(s, a^l) - b(s)$$

Bước 20: Cập nhật Actor θ^l theo gradient:

$$\theta^l \leftarrow \theta^l + \nabla_{\theta^l} \log \pi^l(a^l | o^l) \cdot Adv^l$$

Bước 21: Kết thúc vòng lặp cập nhật COMA, xóa sạch Buffer: $Buffer_l \leftarrow \emptyset$

Kết thúc vòng lặp chính

Bước 22: Sau N_{ep} , trả về bộ tham số đã huấn luyện bao gồm θ^l , ϕ^l đã được huấn luyện bởi LAgent

4.2.2.3 Mã giả

Algorithm 1 HES-COMA(Step 2: Train Local-Level LAgent)

```

1: Initialize  $\theta^l, \phi^l$  randomly
2: Fix  $\theta^g$  from Step 1 {No update on GAgent now}
3: Configure environment  $\mathcal{E}_l$  for local-level training
4: /* GAgent's move action is given by  $\pi_{\theta^g}^g$ , LAgent only acts if
   GAgent = stay */
5: for episode = 1 to  $N_{ep}$  do
6:   Reset  $\mathcal{E}_l$ ; observe initial state  $s_0$  (game info)
7:   Initialize  $\text{Buffer}_l = \emptyset$ 
8:   for  $t = 0$  to EpisodeMaxStep do
9:      $o_t^g \leftarrow \text{PartialObservation}_g(s_t)$  {GAgent obs}
10:     $o_t^l \leftarrow \text{PartialObservation}_l(s_t)$  {LAgent obs}
11:     $a_t^g \leftarrow \pi_{\theta^g}^g(o_t^g)$  {Global action (move or stay)}
12:     $a_t^l \leftarrow \pi_{\theta^l}^l(o_t^l)$  {Local action: shoot, pass, steal...}
13:    if  $a_t^g = \text{stay}$  then
14:      Execute  $a_t^l$  in  $\mathcal{E}_l$ 
15:    else
16:      Execute  $a_t^g$  in  $\mathcal{E}_l$  {Move the agent, no LAgent action here}
17:    end if
18:    Observe  $s_{t+1}, r_t^l, d$ 
19:     $\text{Buffer}_l \leftarrow \text{Buffer}_l \cup \{(s_t, o_t^l, a_t^l, r_t^l, s_{t+1}, d)\}$ 
20:     $s_t \leftarrow s_{t+1}$ 
21:    if  $d$  is true then
22:      break
23:    end if
24:  end for
25:  // COMA Update for LAgent
26:  for each  $(s, o^l, a^l, r^l, s', d)$  in  $\text{Buffer}_l$  do
27:    Compute  $Q_{\phi^l}^{\text{central}}(s, a^l)$ 
28:    Compute baseline  $b(s) = \sum_{a^l} \pi_{\theta^l}^l(a^l|o^l) Q_{\phi^l}^{\text{central}}(s, a^l)$ 
29:     $\delta_t \leftarrow r^l + \gamma Q_{\phi^l}^{\text{central}}(s', a^l) - Q_{\phi^l}^{\text{central}}(s, a^l)$ 
30:    Update Critic  $\phi^l$  by minimizing  $(\delta_t)^2$ 
31:     $\text{Adv}^l \leftarrow Q_{\phi^l}^{\text{central}}(s, a^l) - b(s)$  {counterfactual advantage}
32:    Update Actor  $\theta^l$  using  $\nabla_{\theta^l} \log \pi^l(a^l|o^l) \text{Adv}^l$ 
33:  end for
34:   $\text{Buffer}_l \leftarrow \emptyset$ 
35: end for
36: Return  $\theta^l, \phi^l$  {Trained LAgent (local)}

```